SISTEMAS AVANZADOS DE LA PRODUCCION 9BN

TALLER #2

KAREN GERALDINE CAMACHO PINILLA 122795
ERIKA PAOLA ZAMORA BERNAL-14668
LAURA CAMILA ESCANDON-84383

UNIVERSIDAD ECCI
FACULTAD DE INGENIERÍA
DIRECCIÓN DE INGENIERÍA INDUSTRIAL
BOGOTÁ D.C. COLOMBIA
2026

Introducción

El presente análisis aborda el reto de gestionar la demanda de bicicletas en un entorno urbano, un problema complejo influenciado por factores climáticos y temporales. El objetivo principal es transformar datos históricos en decisiones estratégicas mediante dos enfoques: primero, la optimización a través de modelos de regresión para predecir el volumen exacto de uso; y segundo, la clasificación mediante redes neuronales para categorizar el impacto de las campañas publicitarias. Al integrar estas técnicas, se busca maximizar la disponibilidad del servicio, reducir costos operativos y garantizar que la infraestructura responda eficientemente a las necesidades de movilidad de los usuarios.

Fase 1: Desarrollo Analítico Regularización Ridge

Tarea de derivación matemática

Utilizando álgebra matricial, demuestre paso a paso como se llega a la solución cerrada del estimador Ridge. Para ello, siga esta ruta lógica:

Forma Matricial

$$J(\beta) = (y - x\beta)^T (y - x\beta) + \lambda \beta^T \beta$$

Expansión

$$(y - x\beta)^T (y - x\beta) = y^T y - y^T x\beta - \beta^T x^T y + \beta^T x^T x \beta$$

Simplificación

$$J(\beta) = y^T y - 2\beta^T x^T y + \beta^T x^T x\beta + \lambda \beta^T \beta$$

Agrupación

$$J(\beta) = y^T y - 2\beta^T x^T y + \beta^T (x^T x + \lambda I)\beta$$

Derivada

$$\frac{\partial J(\beta)}{\partial \beta} = -2x^T y + 2(x^T x + \lambda I)\beta$$

Igualar a Cero

$$-2x^T y + 2(x^T x + \lambda I)\beta = 0$$

Despeje

$$(x^T x + \lambda I)\beta = x^T y$$

$$\hat{\beta} = (x^T x + \lambda I)^{-1} x^T y$$

Preguntas Fase 1.

Sobre la Invertibilidad: ¿Por qué la suma de λI garantiza que la matriz resultante sea invertible incluso si XT X es singular (no invertible)?

RESPUESTA: Para la primera pregunta, la suma de λI garantiza la vertibilidad porque añade valores positivos a la diagonal de XT X, lo que convierte a la matriz resultante en una matriz definida positiva y elimina cualquier singularidad técnica, permitiendo que siempre exista una inversa incluso ante una fuerte correlación entre variables.

Efecto del Parámetro λ: ¿Qué sucede con el modelo y sus coeficientes cuando λ → 0? ¿Y qué ocurre cuando λ → ∞? Explique en términos de la complejidad del modelo (Sesgo vs. Varianza).
RESPUESTA: Cuando el parámetro λI tiende a cero, la penalización por la magnitud de los coeficientes desaparece y el modelo se convierte en una regresión de mínimos cuadrados ordinarios, lo que produce un bajo sesgo, pero una alta varianza debido a su sensibilidad al ruido de los datos. Por el contrario, cuando λI tiende al infinito, la prioridad absoluta del algoritmo es minimizar la penalización, lo que obliga a los coeficientes a acercarse a cero y resulta en un modelo extremadamente simple con baja varianza, pero un alto sesgo, ya que pierde la capacidad de capturar la relación real entre las variables.

Fase 2. Optimización Numérica y Descenso de Gradiente

Tarea de experimentación

Utilizando la visualización de la superficie 3D y las curvas de nivel generadas por la malla (np.meshgrid), realice las siguientes variaciones y documente los cambios observados en la trayectoria del algoritmo:

2.1 Impacto de la Tasa de Aprendizaje (η):

--- CONFIGURACIÓN DE LA SIMULACIÓN ---

start_point = [0.0, 0.1]

learning_rate = 0.0001 # Tasa de aprendizaje

num_iterations = 1000 # Número de pasos

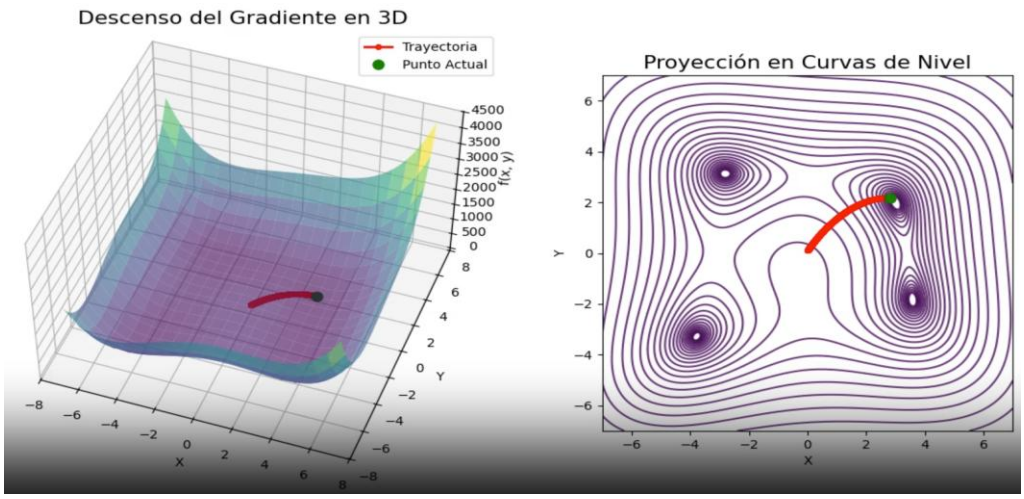

Figura No. 1

Análisis de la gráfica:

En la gráfica 3D se observa la superficie del error, mientras que la gráfica de contornos muestra sus niveles. La línea roja representa la trayectoria que sigue el algoritmo desde un punto inicial. Por otro punto verde indica el mínimo al que se intenta llegar. Se evidencia cómo el algoritmo avanza iterativamente en dirección opuesta al gradiente.

La trayectoria es suave, lo que sugiere una tasa de aprendizaje adecuada.

Incremente el learning rate a un valor significativamente más alto (ej. 0.5 o 1.0)

--- CONFIGURACIÓN DE LA SIMULACIÓN ---

start_point = [0.0, 0.1]

learning_rate = **0.1** # Tasa de aprendizaje

num_iterations = 1000 # Número de pasos

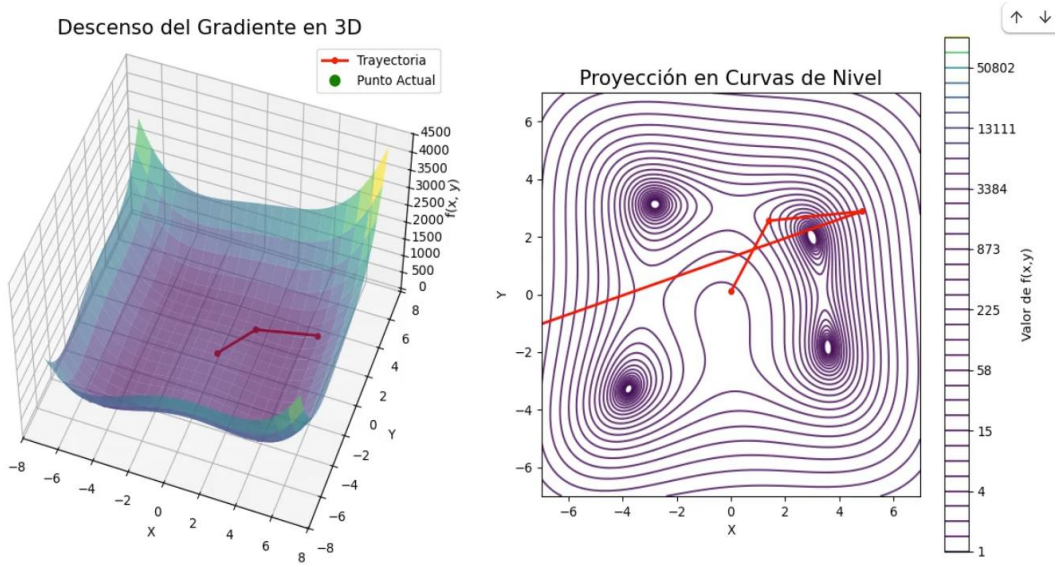

Figura No. 2

Análisis de la gráfica:

La Grafica muestra el comportamiento del descenso de gradiente con una tasa de aprendizaje relativamente alta (0.1)**.** por otro lado, en la gráfica de contornos, la trayectoria roja evidencia saltos largos e irregulares entre iteraciones. Esto indica que el algoritmo no sigue un camino suave hacia el mínimo. Se observa que incluso se aleja momentáneamente de la zona óptima, lo que refleja inestabilidad. En la superficie 3D, la trayectoria no desciende de forma progresiva, sino que presenta cambios bruscos. Este comportamiento sugiere que el learning rate es demasiado alto para la forma de la función**.**

--- CONFIGURACIÓN DE LA SIMULACIÓN ---

start_point = [0.0, 0.1]

learning_rate = **0.2** # Tasa de aprendizaje

num_iterations = 1000 # Número de pasos

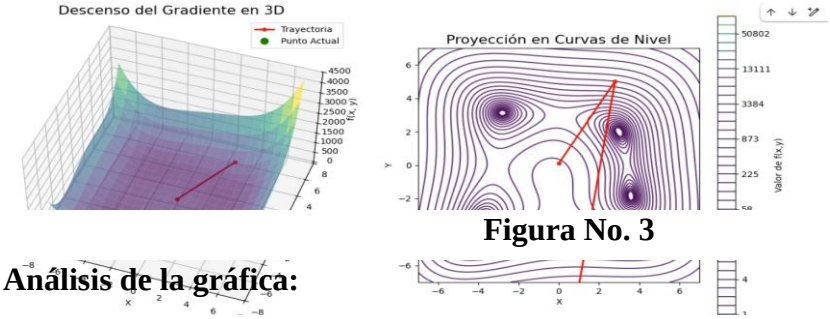

Figura No. 3

Análisis de la gráfica:

La imagen muestra el comportamiento del descenso de gradiente con una tasa de aprendizaje de 0.2, mayor que la anterior. En la gráfica de contornos, la trayectoria roja presenta saltos aún más grandes y descontrolados. Se observa que el algoritmo se aleja considerablemente del punto inicial y del posible mínimo. El recorrido no sigue una dirección estable hacia el óptimo.

--- CONFIGURACIÓN DE LA SIMULACIÓN ---

start_point = [0.0, 0.1]

learning_rate = **0.5** # Tasa de aprendizaje

num_iterations = 1000 # Número de pasos

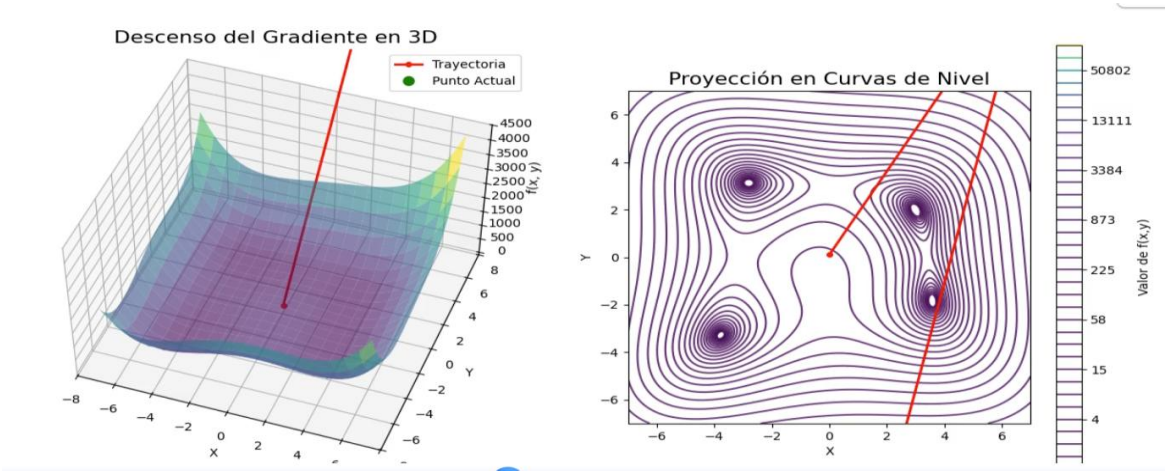

Figura No. 4

Análisis de la gráfica:

La grafica muestra el comportamiento del descenso de gradiente con una tasa de aprendizaje muy alta (0.5)**.** la trayectoria presenta saltos extremadamente grandes y descontrolados. El algoritmo se aleja rápidamente de la zona del mínimo, evidenciando divergencia. No se

observa un camino progresivo hacia la convergencia. En la gráfica 3D, la trayectoria es casi vertical, lo que indica cambios abruptos en la función**.** El modelo pierde completamente la capacidad de ajustarse al mínimo.

¿Qué sucede con la trayectoria? ¿Logra llegar al centro de las curvas de nivel o comienza oscilar/divergir?

Respuestas: No logra llegar al centro de las curvas de nivel (el mínimo).
Por el contrario, el algoritmo comienza a divergir, moviéndose bruscamente de un punto a otro sin seguir un camino de descenso adecuado. En conclusión, la trayectoria no converge, sino que se vuelve inestable y se aleja del óptimo debido a la tasa de aprendizaje demasiado alta.

Reduzca el learning rate a un valor extremadamente pequeño (ej. 10−7).

--- CONFIGURACIÓN DE LA SIMULACIÓN ---

start_point = [0.0, 0.1] # Tasa de aprendizaje

learning_rate = 0.0000001

num_iterations = 1000 # Número de pasos

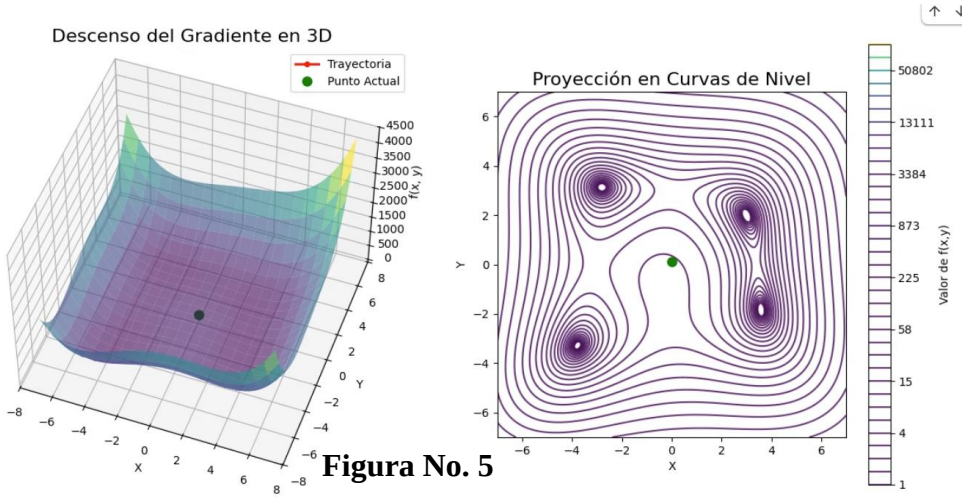

Figura No. 5

Análisis de la gráfica:

La grafica muestra el comportamiento del descenso de gradiente con una tasa de aprendizaje extremadamente pequeña (0.0000001)**.** En la gráfica de contornos, el punto prácticamente no se desplaza del punto inicial**.** La trayectoria es casi inexistente, lo que indica que los pasos del algoritmo son demasiado pequeños.

Observe el resultado tras 1000 iteraciones. ¿Es suficiente este tiempo de cómputo para alcanzar el mínimo?

Respuesta: No, este tiempo de cómputo (1000 iteraciones) no es suficiente para alcanzar el mínimo, ya que la tasa de aprendizaje es tan baja que el algoritmo apenas logra moverse hacia el óptimo.

2.2 Dependencia del punto inicial

Modifique el start point a coordenadas alejadas del origen, por ejemplo [6.0, -6.0] o [-5.0, 5.0].

--- CONFIGURACIÓN DE LA SIMULACIÓN ---

start_point = **[-5.0, 5.0]**

learning_rate = 0.0001 # Tasa de aprendizaje

num_iterations = 1000 # Número de pasos

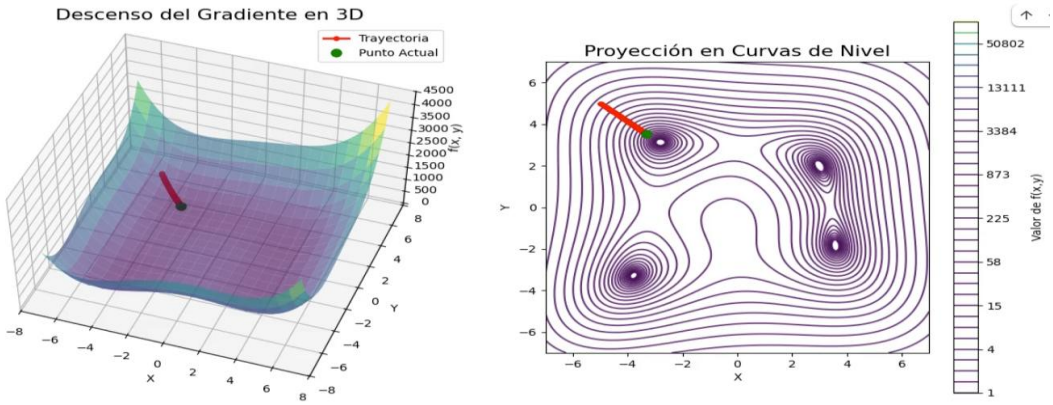

Figura No.6

Análisis de la gráfica:

Esta simulación de Descenso del Gradiente muestra cómo un algoritmo busca el punto más bajo de una superficie. Con una tasa de aprendizaje muy pequeña 0.0001, el avance es sumamente lento y preciso, evitando oscilaciones bruscas. La trayectoria roja indica que el sistema ha convergido exitosamente hacia el mínimo local más cercano a su origen. Sin embargo, al quedar atrapado en este valle, el algoritmo demuestra su incapacidad para alcanzar el mínimo global sin parámetros más agresivos.

--- CONFIGURACIÓN DE LA SIMULACIÓN ---

start_point = **[6.0, -6.0]**

learning_rate = 0.0001 # Tasa de aprendizaje

num_iterations = 1000 # Número de pasos

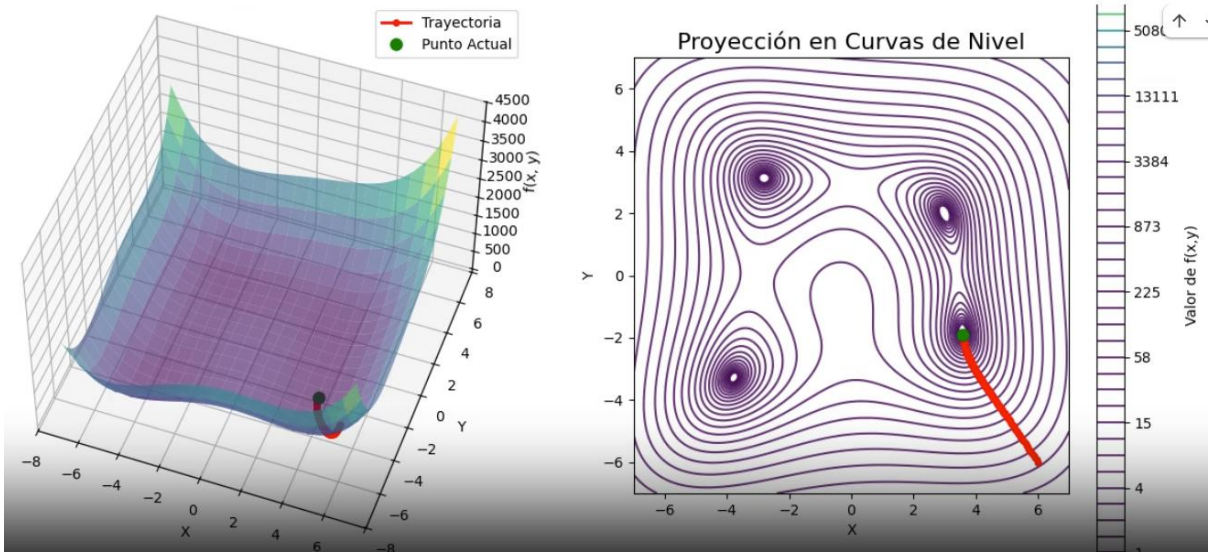

Figura No. 7

Análisis de la gráfica:

Esta gráfica muestra el algoritmo de Descenso del Gradiente iniciando en el punto 6.0, -6.0. Con una tasa de aprendizaje baja, el sistema avanza de forma lenta y controlada, "bajando" por la pendiente de la superficie 3D. La trayectoria roja indica que el algoritmo se dirige hacia el mínimo local inferior derecho, quedando atrapado en ese valle. En resumen, el modelo logra minimizar la función con precisión, pero debido a su configuración, se detiene en el pozo de potencial más cercano a su punto de partida en lugar de buscar un valor más bajo en otra región.

¿El algoritmo llega siempre al mismo punto final? Explique si la topografía de la función f(X, Y) sugiere la presencia de múltiples valles o mínimos locales.

Respuesta: No, el algoritmo no llega siempre al mismo punto porque su destino final depende estrictamente de dónde comience el recorrido. La topografía de la función muestra claramente múltiples mínimos locales (se observan cuatro valles distintos en las curvas de nivel), lo que significa que el algoritmo simplemente "cae" en el pozo más cercano a su punto de origen. Como el descenso del gradiente solo busca la pendiente más baja inmediata, queda atrapado en el valle donde inició sin poder saltar hacia otros mínimos que podrían ser más profundos.

Preguntas Fase 2

A partir de sus observaciones en la simulación, responda de manera crítica:

El fenómeno de “Overshooting”: Explique físicamente qué ocurre cuando el paso ($\eta \cdot \nabla f$) es más grande que la distancia al mínimo. ¿Cómo se visualiza esto en el gráfico de curvas de nivel**?**

RESPUESTA: Físicamente, ocurre cuando el paso es tan largo que el algoritmo "salta" por encima del punto más bajo y aterriza en la ladera opuesta, a veces incluso a una altura mayor que la inicial. En el gráfico de curvas de nivel, esto se visualiza como una trayectoria de un lado a otro del valle, en lugar de una línea directa y suave hacia el centro.

Eficiencia Computacional: Si el algoritmo se detiene en la iteración 1000 pero aún se encuentra lejos del mínimo, ¿qué estrategia es mejor: aumentar el número de iteraciones o ajustar la tasa de aprendizaje? Justifique su respuesta.

RESPUESTA: Lo correcto es ajustar la tasa de aprendizaje (aumentarla ligeramente). Si con 1000 iteraciones el avance es insignificante (como se ve en las gráficas), simplemente aumentar las iteraciones a 10,000 o más desperdiciaría mucho tiempo y recursos computacionales para un progreso mínimo. Subir un poco la tasa de aprendizaje permite que cada paso sea más largo, alcanzando el mínimo de forma más rápida y eficiente.

Generalización: En un problema de ingeniería con cientos de variables (como la optimización de una cadena de suministro), ¿por qué es peligroso confiar en un único punto de inicio aleatorio?

RESPUESTA: Es peligroso porque, en problemas con cientos de variables, el modelo tiene miles de mínimos locales (valles falsos). Si confiar en un solo punto de inicio, podría quedar atrapado en una solución muy mala creyendo que es la mejor. Al usar múltiples puntos de inicio aleatorios, aumenta las probabilidades de que al menos una de las trayectorias encuentre el mínimo global, que es la optimización real de la cadena de suministro.

Fase 3. Redes Neuronales (MLP) y Ajuste de Hiper Parámetros

Parte A: Evaluación de Métricas de Regresión

Ejecute el modelo MLPRegressor inicial con la configuración base (hidden layer sizes=(16,8, 4)).

== MLPRegressor ==

Train -> **MAE:** 47.086 **|** RMSE: 68.547 **| R2:** 0.858

Test -> **MAE:** 47.175 **|** RMSE: 69.458 **| R2:** 0.848

MLP_real vs Y_predicha (TEST)

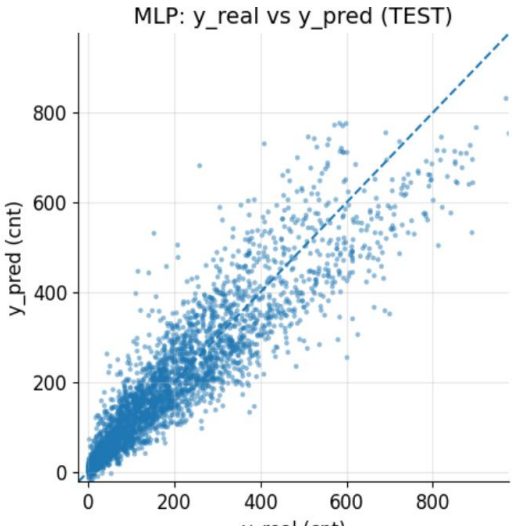

Figura No. 8

Análisis de la gráfica:

El modelo MLPRegressor presenta un desempeño sólido con un R2 de 0.848 en prueba, explicando el 85% de los datos. La mínima diferencia entre las métricas de entrenamiento y prueba confirma que el modelo no tiene sobreajuste y generaliza bien. El error MAE de 47.1 indica una buena precisión promedio, aunque el RMSE más alto sugiere la presencia de algunos valores atípicos. Visualmente, los puntos siguen de cerca la línea de identidad, validando que las predicciones son altamente confiables.

Histograma de Residuales (TEST)

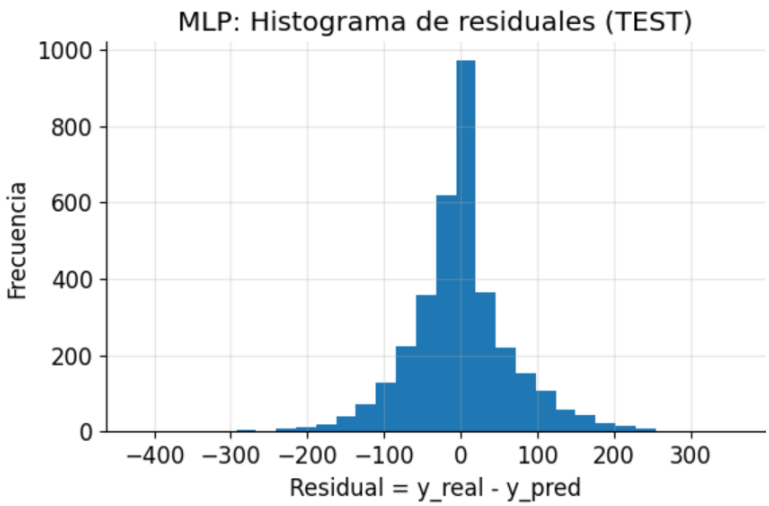

Figura No. 9

Análisis de la gráfica:

El Histograma de Residuales de la Figura No. 9 muestra una distribución centrada en cero, lo que indica que el modelo no tiene un sesgo sistemático importante. La forma de "campana" sugiere que los errores siguen una distribución aproximadamente normal, un supuesto clave para validar la calidad de una regresión.

Curva de pérdida (entrenamiento)

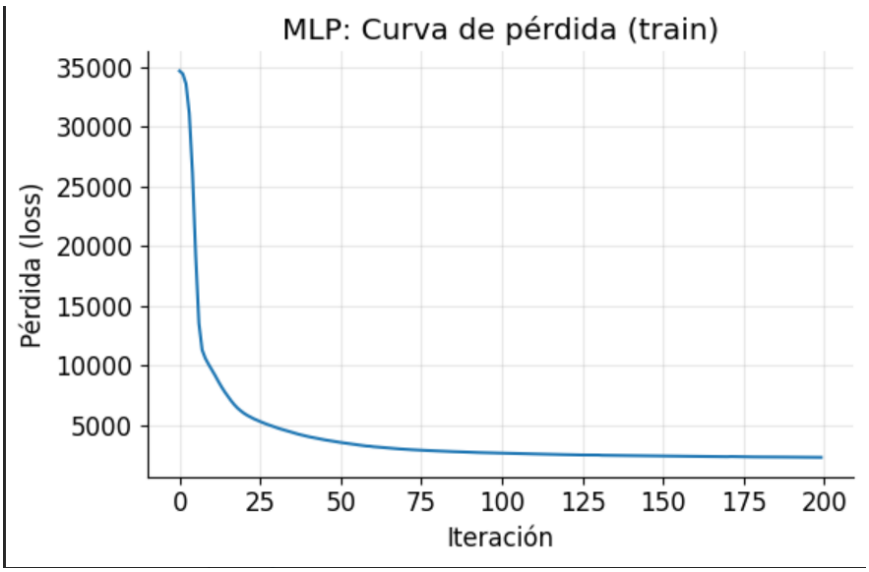

Figura No. 10

Análisis de la gráfica: La Curva de Pérdida de la Figura No. 10 muestra el proceso de aprendizaje del modelo MLP a lo largo de 200 iteraciones. Se observa un descenso abrupto inicial en las primeras 25 iteraciones, lo que indica que el algoritmo encontró rápidamente la dirección correcta para minimizar el error. A partir de la iteración 50, la curva se estabiliza y entra en una fase de convergencia suave, demostrando que el modelo ha dejado de aprender cambios drásticos. La ausencia de oscilaciones bruscas sugiere que la tasa de aprendizaje utilizada es adecuada y estable.

Preguntas Fase 3A:

Diferenciación de Métricas: Explique la diferencia técnica entre el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE). ¿Cuál de las dos penaliza con mayor severidad los errores grandes (outliers) en las ventas y por qué?

RESPUESTA: El MAE mide el promedio de los errores de manera lineal, tratándolos a todos por igual según su magnitud real. Por el contrario, el RMSE eleva los errores al cuadrado antes de promediarlos, lo que hace que penalice con mayor severidad los errores grandes (outliers). Esto ocurre porque, al elevar al cuadrado, un error grande aumenta su peso de forma exponencial en el cálculo final; por ejemplo, un error de 10 aporta 100 unidades al RMSE, dándole mucha más importancia que a los errores pequeños.

Diagnóstico de Desempeño: Si el R2 en el conjunto de entrenamiento es significativamente mayor que en el de prueba, ¿qué fenómeno está ocurriendo? Proponga una solución basada en lo aprendido en la Fase 1 del taller.

RESPUESTA: Cuando EL R2de entrenamiento es mucho mayor que el de prueba, el modelo está sufriendo de Sobreajuste, lo que significa que ha memorizado el ruido de los datos en lugar de aprender el patrón general. La solución, basada en la Fase 1, es aplicar Regularización Ridge mediante el ajuste del parámetro lambda. Esta técnica penaliza los coeficientes grandes, reduciendo la complejidad del modelo (varianza) y obligándolo a generalizar mejor para que su desempeño sea similar tanto en los datos conocidos como en los nuevos.

Interpretación de Residuos: Al observar la gráfica de y real vs y-pred, ¿se identifica algún patrón de error sistemático (ej. subestimación en ventas altas)?

RESPUESTA: se identifica un patrón de subestimación en las ventas altas, específicamente cuando los valores superan las 600 unidades. En esa zona, la mayoría de los puntos se sitúan por debajo de la línea punteada de 45°, lo que indica que el modelo predice valores inferiores a los reales. Este error sistemático sugiere que la red neuronal tiene dificultades para capturar la variabilidad de los picos de demanda máxima. A diferencia de los valores bajos, donde la nube de puntos es densa y centrada, la dispersión aumenta significativamente en el extremo superior.

Parte B: Optimización con GridSearchCV

Tarea de Experimentación: Utilizando la Tabla 2 como guía, modifique la parrilla de parámetros (param grid) en el notebook y ejecute la búsqueda sistemática (GridSearch). Se sugiere variar estratégicamente los siguientes elementos:

Parrilla de hiper parámetros

```
param_grid = {
    "hidden_layer_sizes": [
        (16, 8, 4),    # tu config actual
        (32, 16),      # menos profundo, más ancho
        (32, 16, 8),   # un poco mayor capacidad
        (16, 8)        # más simple
```

== MLP (MEJOR MODELO) ==

Train -> **MAE:** 46.816 | **RMSE:** 68.336 | **R2:** 0.859

Test -> **MAE:** 46.512 | **RMSE:** 68.550 | **R2:** 0.852

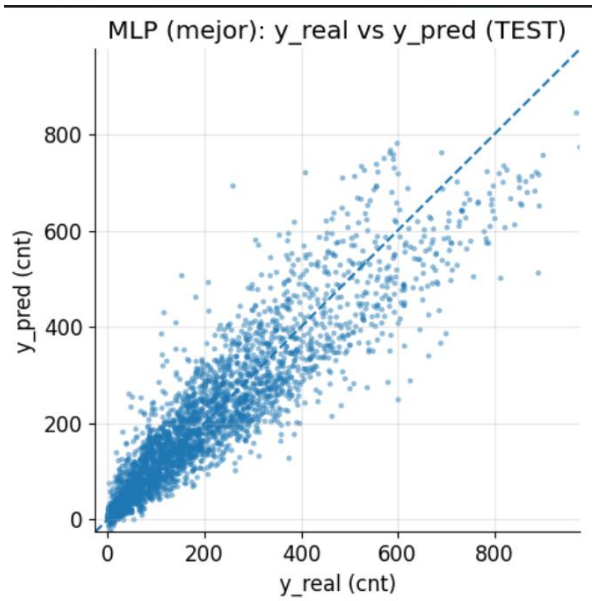

Figura No. 11

Análisis de la gráfica: El análisis del Mejor Modelo tras el GridSearch muestra un R^2 de 0.852, lo que confirma una mejora en la precisión predictiva sobre los datos de prueba. La estabilidad es evidente, ya que los resultados de entrenamiento y test son casi idénticos, garantizando que el modelo generaliza correctamente. Se observa una leve reducción en el MAE (46.5), indicando que, en promedio, las predicciones de ventas están más cerca de los valores reales.

Histograma de Residuales (TEST)

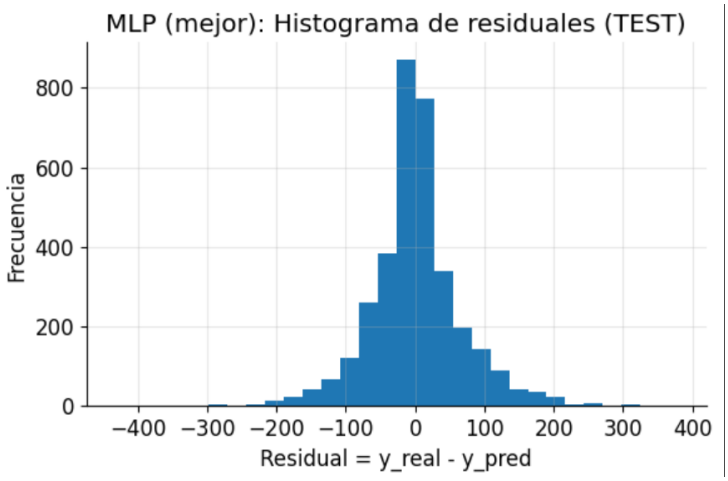

Análisis gráfico: El histograma de residuales del mejor modelo muestra una distribución centrada en **cero**, confirmando que no hay sesgos sistemáticos graves. La mayoría de los errores se concentran en el centro, lo que valida una alta precisión en la mayoría de las predicciones. La forma acampanada sugiere que los errores siguen una distribución normal, ideal para modelos de regresión robustos.

Curva de pérdida (entrenamiento)

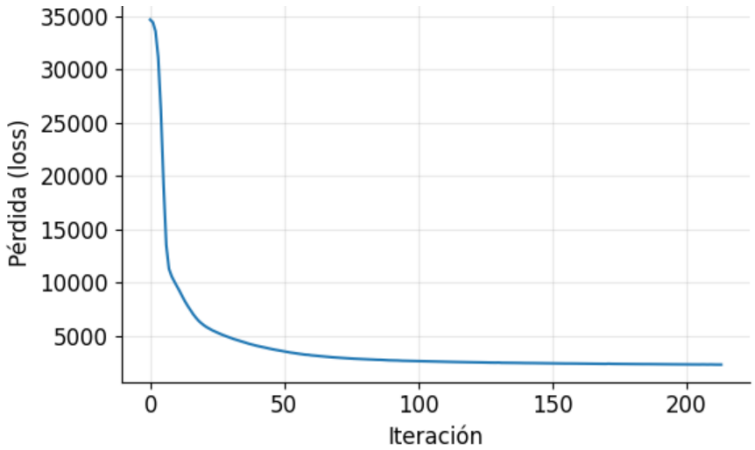

Figura No. 13

Análisis de la clasifica: La curva de pérdida del modelo optimizado muestra un descenso drástico y eficiente durante las primeras 25 iteraciones del entrenamiento. Esta rápida caída indica que la configuración de capas elegida permite al algoritmo encontrar rápidamente patrones clave en los datos.

Fase 4: Propagación hacia Adelante (Forward Propagation) Manual

En esta fase, el objetivo es comprender la mecánica interna de una Red Neuronal Multicapa. En lugar de predecir un valor continuo de ventas, clasificaremos el éxito de una campaña en tres categorías: Bajo Impacto (C1), Impacto Medio (C2) e Impacto Alto (C3).

Tarea de Cálculo Manual

Realice los cálculos paso a paso para determinar a qué categoría pertenece la campaña publicitaria:

	CAPA 1 (Oculta)													
	Entrada		Capa 1				Sesgo		Forma Matricial					Funición de Activación
	X1		W11	W12	W13		b1							
X	X2	$W^{(1)}$	W21	W22	W23	$b^{(1)}$	b2		W(1) * X	+	$b^{(1)}$	=	$Z^{(1)}$	Sigmoide
	X3		W31	W32	W33		b3							
	0,5		0,2	0,5	-0		0,1		0,23	+	0,1	=	0,33	0,581759377
	0,3	$W^{(1)}$	0,8	-0	0,4	$b^{(1)}$	###		0,39	+	###	=	0,19	0,547357618
	0,2		-1	0,1	0,2		0,0		-0,18	+	0,0	=	-0,18	0,455121108

	CAPA 2 (Salida)														
	Entrada		Capa 2				Sesgo		Forma Matricial					Funición de Activación	
	Z1		W11	W12	W13		b1								
$Z^{(1)}$	Z2	$W^{(2)}$	W21	W22	W23	$b^{(2)}$	b2		$W^{(2)}$ * Z	+	$b^{(2)}$	=	$Z^{(2)}$	Softmax	
	Z3		W31	W32	W33		b3								
															SALIDAS
	0,581759377		0,5	-0	0,1		###		0,117	+	###	=	0,0	0,231235905	**23,1%** C1
$Z^{(1)}$	0,547357618	$W^{(2)}$	0,2	0,8	-1	$b^{(2)}$	0,2		0,327	+	0,2	=	0,5	0,384778209	**38,5%** C2
	0,455121108		-0	0,3	0,7		0,1		0,425	+	0,1	=	0,5	0,383985886	**38,4%** C3

Salidas: Probabilidad para cada clase:

Z1 = 23,1 % Bajo Impacto (C1)

Z2 = 38,5 % Medio Impacto (C2)

Z3 = 38,4 % Alto Impacto (C3)

Al analizar las probabilidades finales generadas por la red, la campaña publicitaria se clasifica dentro de la categoría de Impacto Medio (C2), alcanzando un 38,5% de probabilidad. Es fundamental resaltar que existe un margen extremadamente estrecho con la categoría de Alto Impacto (C3), la cual obtuvo un 38,4%; esta diferencia de apenas el 0,1% indica que la campaña está en el límite superior de su categoría actual. Por último, la opción de Bajo Impacto (C1) se sitúa en un distante tercer lugar con un 23,1% de probabilidad.

Preguntas Fase 4

Interpretación de Resultados: Según las probabilidades obtenidas, ¿en qué categoría clasifica la red a esta campaña publicitaria?

RESPUESTA: De acuerdo con las probabilidades de la columna SALIDAS, la red clasifica esta campaña publicitaria en la categoría de Impacto Medio (C2). Esto se debe a que presenta el valor más alto con un 38,5%. Sin embargo, es una clasificación muy reñida, ya que la categoría de Alto Impacto (C3) le sigue casi de forma idéntica con un 38,4%, dejando al Bajo Impacto (C1) en último lugar con un 23,1%.

Función de Activación: ¿Por qué utilizamos Softmax en la última capa en lugar de una

función lineal o una sigmoide simple? Explique en términos de la suma de las probabilidades.

RESPUESTA: Se prefiere Softmax en la capa de salida porque, a diferencia de una sigmoide simple o una función lineal, esta garantiza que la suma de todas las salidas sea exactamente 1 (100%). Esto permite interpretar los resultados como una distribución de probabilidad real donde las clases compiten entre sí. Si usáramos una función lineal, obtendríamos valores arbitrarios difíciles de comparar, y con una sigmoide, las probabilidades de cada clase serían independientes y no sumarían la unidad.

Rol del Bias: ¿Qué sucedería con la capacidad de representación de la red si todos los vectores de sesgo (b) fueran cero?

RESPUESTA: Si todos los vectores de sesgo (b) fueran cero, la red perdería su capacidad de "desplazar" las funciones de activación, obligándolas a pasar siempre por el origen. Esto limitaría severamente la flexibilidad del modelo para ajustar las fronteras de decisión; básicamente, la red solo podría aprender patrones que sean linealmente proporcionales a las entradas, reduciendo drásticamente su precisión en escenarios donde los datos no están perfectamente centrados.

Fase 5: Evaluación de Modelos y Toma de Decisiones (Caso: Mantenimiento Predictivo)

En la manufactura, una parada de máquina no planificada es un fallo crítico que genera cuellos de botella y sobrecostos. En esta fase, evaluaremos el desempeño de la Red Neuronal entrenada para el Mantenimiento Predictivo (PdM), donde el objetivo es clasificar si una máquina fallará. (Clase 1) o no (Clase 0).

El Desafío del Desbalance de Clases

En plantas reales, las máquinas fallan rara vez (menos del 5% del tiempo). Esto genera un dataset desbalanceado. Observe en el código del notebook cómo se calculó el diccionario class weights dict para manejar esta situación.

Preguntas Fase 5A:

Análisis de Pesos: Si el modelo indica que los errores en la Clase 1 (Fallo) pesarán aproximadamente 14.7 veces más que en la Clase 0, ¿qué intenta corregir el algoritmo al configurar el parámetro class Wright durante el entrenamiento?

```python
# 3. Entrenar el modelo
print("\nEntrenando la red...")
history = model_nn.fit(
    X_train_scaled,
    y_train,
    epochs=30,            # Número de veces que el modelo ve todos los datos
    batch_size=64,        # Cuántas muestras procesar antes de actualizar pesos
    validation_split=0.2, # Usar 20% de los datos de entreno para validación
    class_weight=class_weights_dict,
    verbose=1             # Mostrar progreso
)

print("¡Modelo Red Neuronal entrenado!")
```

```
Pesos de Clase calculados: {0: np.float64(0.51753137533963), 1: np.float64(14.760147601476016)}
Esto significa que los errores en la Clase 1 (Fallo) pesarán ~14.7 veces más.

Entrenando la red...
Epoch 1/30
100/100 ━━━━━━━━━━━━━━━━━━━━ 2s 5ms/step - Recall: 0.5185 - accuracy: 0.7519 - loss: 0.8566 - val_Recall: 1.0000 - val_accuracy: 0.8731 - val_loss: 0.5417
Epoch 2/30
100/100 ━━━━━━━━━━━━━━━━━━━━ 0s 3ms/step - Recall: 0.8333 - accuracy: 0.8230 - loss: 0.4316 - val_Recall: 1.0000 - val_accuracy: 0.9875 - val_loss: 0.3641
Epoch 3/30
100/100 ━━━━━━━━━━━━━━━━━━━━ 0s 3ms/step - Recall: 0.9028 - accuracy: 0.9305 - loss: 0.2691 - val_Recall: 1.0000 - val_accuracy: 0.9987 - val_loss: 0.2044
Epoch 4/30
100/100 ━━━━━━━━━━━━━━━━━━━━ 0s 3ms/step - Recall: 0.9444 - accuracy: 0.9688 - loss: 0.1797 - val_Recall: 1.0000 - val_accuracy: 0.9994 - val_loss: 0.1095
Epoch 5/30
100/100 ━━━━━━━━━━━━━━━━━━━━ 0s 3ms/step - Recall: 0.9259 - accuracy: 0.9791 - loss: 0.1640 - val_Recall: 1.0000 - val_accuracy: 1.0000 - val_loss: 0.0725
Epoch 6/30
```

Al configurar el parámetro, el algoritmo intenta mitigar el desequilibrio de clases presente en el conjunto de datos. En este caso, al asignar un peso de 14.7 a la Clase 1, se compensa la escasez de ejemplos de "Fallo" frente a la clase mayoritaria. Esto penaliza con mayor severidad los errores cometidos en la clase minoritaria durante el ajuste de pesos, obligando a la red a no ignorar estos casos críticos. El objetivo final es mejorar la sensibilidad o Recall, garantizando que el modelo aprenda a identificar correctamente los fallos aunque aparezcan con poca frecuencia. Así, se evita que el sistema desarrolle un sesgo hacia la clase más común, logrando una clasificación mucho más equitativa y funcional.

La Trampa de la Exactitud: Explique por qué en este caso un Accuracy del 95% podría considerarse un resultado deficiente para la gestión de mantenimiento si el modelo no logra detectar los fallos reales.

RESPUESTA: Para este caso, considerar un Accuracy del 95% de Accuracy es insuficiente si el modelo falla en detectar la clase minoritaria (los fallos reales). Si el 95% de los datos son "operaciones normales", el modelo podría predecir siempre que todo está bien y aun así tener una exactitud alta, siendo totalmente inútil para prevenir averías. El costo de un falso negativo (no detectar un fallo) es crítico, provocando paradas costosas y daños materiales. Por ello, la exactitud no garantiza seguridad; lo que realmente importa es el Recall (sensibilidad) para capturar cada anomalía. En resumen, un modelo que no detecta fallos falla en su propósito principal, sin importar qué tan alto sea su porcentaje de acierto general.

Interpretación de la Matriz de Confusión

Utilice la matriz de confusión generada por el heatmap de Seaborn en su notebook para completar el siguiente análisis. Suponga que, para su planta de producción, el costo de una

reparación no planificada (Fallo Real no detectado) es de USD 5,000 y el costo de una inspección preventiva innecesaria (Falsa Alarma) es de USD 200.

```
--- Matriz de Confusión (Red Neuronal) ---
```

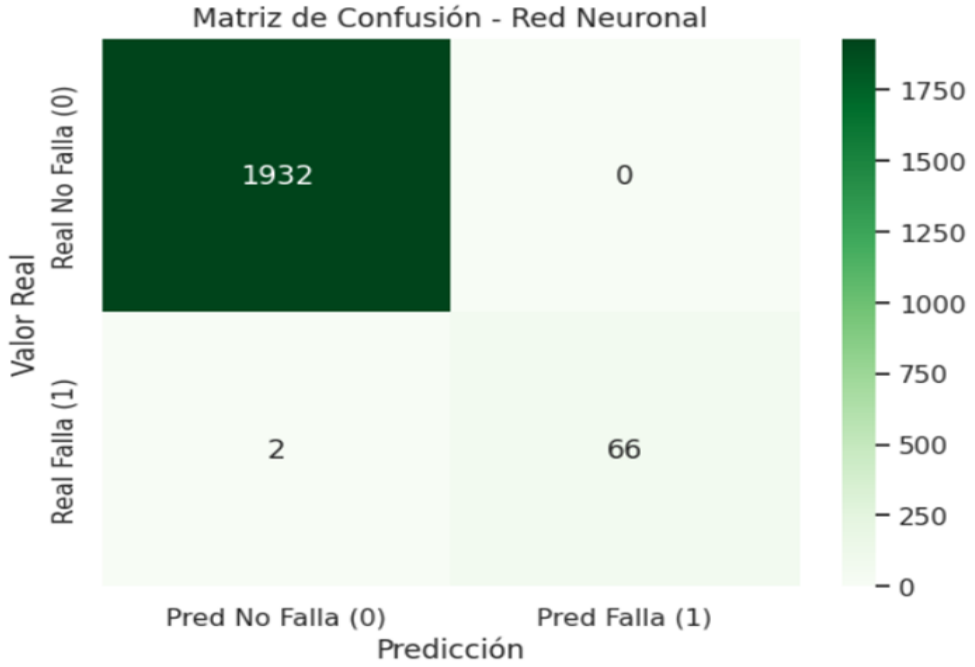

Tarea de Cálculo de Métricas: A partir de los valores obtenidos en su matriz de confusión (TN, FP, FN, TP), calcule manualmente:

RESPUESTA:

(TN, FP, FN, TP), calcule manualmente:

TN (Verdaderos Negativos): 1932

FP (Falsos Positivos): 0

FN (Falsos Negativos): 2

TP (Verdaderos Positivos): 66

1. Precision (Precision): TP/TP+FP = 66/66+0 = 1,0000 (100%)

1. Precision (Precision): ¿Qué tan confiable es el modelo cuando emite una alerta de falla? Este modelo es muy confiable. Cuando emite una alerta de Falla, tiene una confiabilidad del 100%, es decir, que es capaz de predecir cuándo va a fallar y así efectivamente se cumple. Esto significa que el personal de mantenimiento no perderá tiempo nunca en inspecciones innecesarias; si el modelo está avisando, es porque realmente hay un problema o falla.

2. Recall (Sensibilidad): ¿Qué porcentaje de los fallos reales totales logró capturar el modelo?

2. Recall (Sensibilidad): TP/TP+FN = 66/66+2 = 0,9706 (97,06%)

RESPUESTA: Con una capacidad de detección del 97%, el sistema demostró una eficacia sobresaliente al identificar casi la totalidad de las averías reales. El hecho de que solo se omitieran 2 fallos entre 68 casos totales refuerza la seguridad operativa, minimizando drásticamente el riesgo de paradas imprevistas. Esta alta sensibilidad asegura que la planta esté protegida bajo un monitoreo constante y preciso. Al reducir los puntos ciegos, el modelo se convierte en una herramienta de confianza para la toma de decisiones preventivas.

3. Costo Total de Error: Calcule el impacto económico mensual del modelo utilizando la fórmula:

RESPUESTA: Costo = (FN * 5000) + (FP * 200)

Costo = (2 * 5000) + (0 * 200) = 10000

Preguntas de Reflexión y Negocio Fase 5

Trade-off entre Recall y Precisión: En el contexto de evitar paradas de línea críticas, ¿Prefiere usted un modelo con un Recall del 98% pero una Precisión del 60%, o viceversa? Justifique su respuesta basándose en los costos calculados anteriormente.

RESPUESTA: La elección de un modelo con 98% de Recall y 60% de Precisión es la decisión financiera más acertada debido a la asimetría de costos. Dado que omitir un fallo es 25 veces más caro que una inspección innecesaria (USD 5000 frente a USD 200), es preferible gestionar múltiples falsas alarmas que permitir una sola avería imprevista. Con esta configuración, el costo de las omisiones se reduce drásticamente a USD 10,000 anuales, mientras que un modelo con menor sensibilidad elevaría las pérdidas a USD 200,000 por paradas no detectadas. Aunque la precisión del 60% genera algunas alertas en vano, este gasto es insignificante frente al ahorro masivo que supone blindar la operatividad de la planta. En definitiva, priorizamos capturar el riesgo catastrófico, asegurando que prácticamente ninguna falla crítica pase desapercibida

Curva de Aprendizaje: Observe la gráfica de los (perdida) y accuracy durante el entrenamiento.

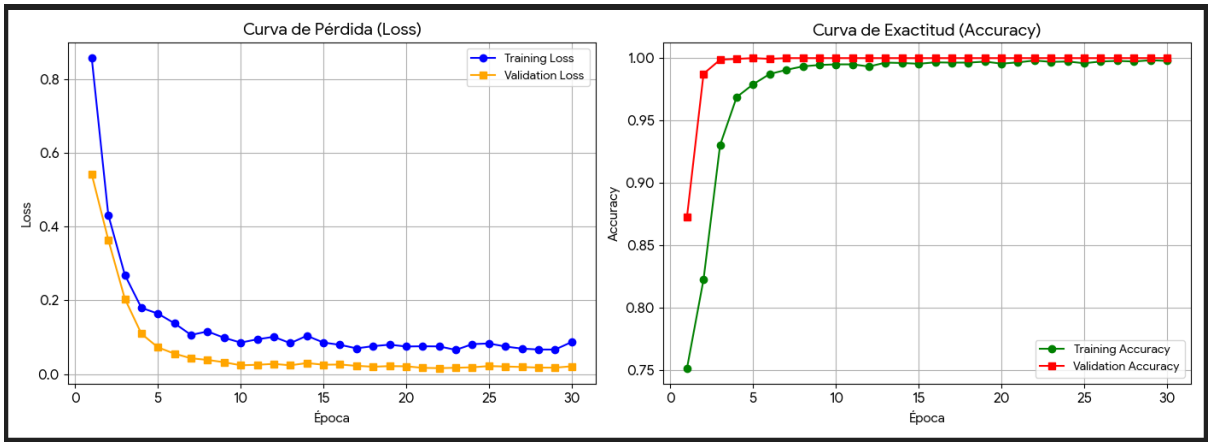

¿Considera que 30 épocas son suficientes para que el modelo converja?

RESPUESTA: Las 30 épocas han sido más que suficientes para que el modelo converja. Se observa que tanto la pérdida como la exactitud alcanzan una fase de estabilidad aproximadamente a partir de la época 10. A partir de ese punto, las mejoras son marginales, lo que indica que la red ya ha aprendido los patrones fundamentales de los datos y no requiere ciclos adicionales de entrenamiento para optimizar sus parámetros. Continuar el proceso por mucho más tiempo podría ser innecesario en términos de cómputo, ya que el modelo ya ha llegado a su punto de equilibrio.

¿Qué sucede con el error de validación comparado con el de entrenamiento?

RESPUESTA: En cuanto al error de validación, este muestra un comportamiento ideal y saludable, situándose incluso por debajo del error de entrenamiento de forma consistente. Ambas curvas descienden en paralelo sin divergir, lo que descarta cualquier signo de *overfitting* (sobreajuste). El hecho de que la pérdida de validación sea menor y la exactitud de validación sea superior a las de entrenamiento sugiere que el modelo tiene una excelente capacidad de generalización, comportándose de manera robusta al enfrentarse a datos nuevos que no vio durante la fase de aprendizaje.

Conclusión Final del Taller:

Tras recorrer desde la regresión analítica hasta la clasificación con redes neuronales, ¿cómo puede el uso de métricas avanzadas (como el Recall) transformar la rentabilidad de una empresa de manufactura?

RESPUESTA: El uso del Recall maximiza la rentabilidad al priorizar la detección de fallos críticos, evitando paradas de producción que son financieramente catastróficas. Al enfocarse en esta métrica, la empresa reduce drásticamente los costos por averías no detectadas, los cuales superan por mucho el gasto de una revisión preventiva. Esto permite transitar de un modelo reactivo a uno predictivo que blinda la operatividad y asegura el cumplimiento de entregas.

Conclusiones:

Reflexión sobre la arquitectura de red óptima y la importancia de las métricas de sensibilidad en entornos industriales